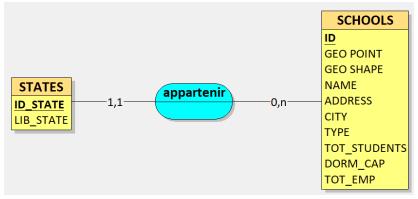
Informatique S4 : Bases de Données Projet pratique N°2 US Colleges and Universities

ETAPE 1 : Structuration des données, lien avec Python

i. Téléchargement du Data set us-colleges-and-universities.csv sur kaggle.com et nettoyage (nettoyer-us-colleges-and-universities.csv)

ii. Rétro conception

1. Le modèle Entité/Association



Réalisé avec Looping

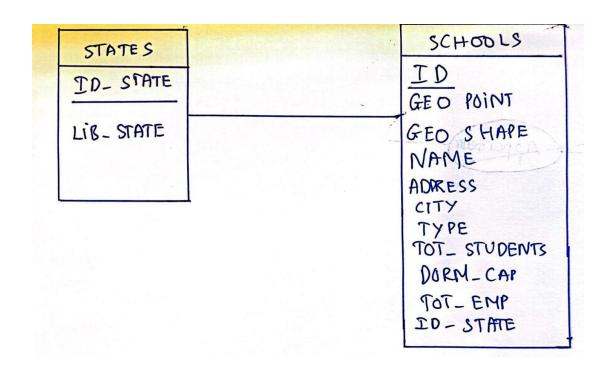
Lecture : 0 à N écoles appartiennent à 1 état et 1 état possède 0 à N écoles.

2. Les relations et les schémas relationnels

SCHOOLS (<u>ID</u>, GEO POINT, GEO SHAPE, NAME, ADDRESS, CITY, TYPE, TOT_STUDENTS, DORM_CAP, TOT_EMP, #ID_STATE)
STATES (<u>ID_STATE</u>, LIB_STATE)

3. Les schémas relationnels précédents sont normalisés en 3FN car tout attribut dépend fonctionnellement de la clé primaire (1FN), tout attribut dépend de toute la clé (2FN) et il n'existe aucune dépendance fonctionnelle entre les attributs non-clé.

4. Le modèle physique:



iii. Data Analyse, lien avec EXCEL

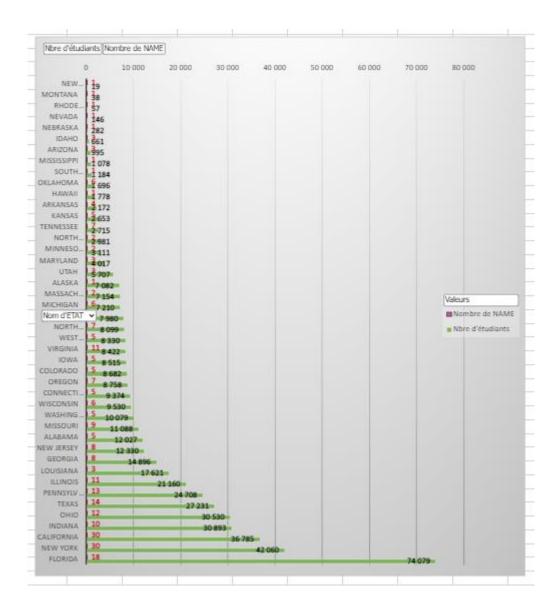
1. Utilisation des fonctions mathématiques simples d'EXCEL Exemple sur la colonne J "TOT_STUDENTS"

Fonction	Résultat			
=MOYENNE(J2:J287)	1733,96153846154			
=MEDIANE(J2:J287)	492,5			
=MIN(J2:J287)	2			
=MAX(J2:J287)	23980			
=SOMME(J2:J287)	495913			
=ECARTYPE(J2:J287)	3117,35154380098			
=VAR(J2:J287)	9717880,64763834			

Tableau croisé dynamique avec le nombre d'étudiants et d'écoles par état

3	Nom d'ETAT	Nbre d'étudiants	Nombre de NAME
4	FLORIDA	74 079	18
5	NEW YORK	42 060	30
6	CALIFORNIA	36 785	30
7	INDIANA	30 893	10
8	OHIO	30 530	12
9	TEXAS	27 231	14
10	PENNSYLVANIA	24 708	13
11	ILLINOIS	21 160	11
12	LOUISIANA	17 621	3
13	GEORGIA	14 896	8
14	NEW JERSEY	12 330	8
15	ALABAMA	12 027	5
16	MISSOURI	11 088	9
17	WASHINGTON	10 079	5
18	WISCONSIN	9 530	6
19	CONNECTICUT	9 374	5
20	OREGON	8 758	7
21	COLORADO	8 682	5
22	IOWA	8 515	5
23	VIRGINIA	8 422	11
24	WEST VIRGINIA	8 330	5
25	NORTH CAROLINA	8 099	7
26	KENTUCKY	7 980	4
27	MICHIGAN	7 210	6
28	MASSACHUSETTS	7 154	2
29	ALASKA	7 082	1
30	UTAH	5 707	3
31	MARYLAND	4 017	3
32	MINNESOTA	3 111	2
33	NORTH DAKOTA	2 981	2
34	TENNESSEE	2 715	7
35	KANSAS	2 653	5
36	ARKANSAS	2 172	4
37	HAWAII	1 778	1
38	OKLAHOMA	1 696	6
39	SOUTH CAROLINA	1 184	1
40	MISSISSIPPI	1 078	1
41	ARIZONA	995	3
42	IDAHO	661	2
43	NEBRASKA	282	1
44	NEVADA	146	1
45	RHODE ISLAND	57	1
46	MONTANA	38	1
47	NEW MEXICO	19	1
48	Total général	495 913	286

2. Histogramme avec le nombre d'étudiants et d'écoles par état



iv. Lien avec Python

1. Création d'une 4ème table et alimentation à partir d'un programme Python : Première méthode en utilisant pandas :

```
      View
      Go
      Run
      Terminal
      Help
      ← →
      Projet dataset

      ...
      ★ tablepython.ipynb > ...
      ★ tablepython.ipynb > ...
      ★ CorrectionTD12 (3).py
      ★ datasetInfoS4.csv
      ★ requirement.txt

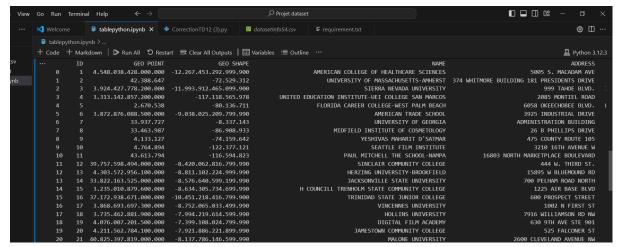
      + Code
      ★ Markdown
      ★ Run All
      ★ Restart
      ★ Clear All Outputs
      ★ Variables
      ★ Outline
      ...

      import pandas as pd

      import pandasql as ps
      ★ Charger les données à partir du fichier CSV en spécifiant les noms de colonnes et en sautant la première ligne

      data = pd.read_csv("datasetInfoS4.csv", delimiter=';',header=0)
      ★ Afficher le DataFrame

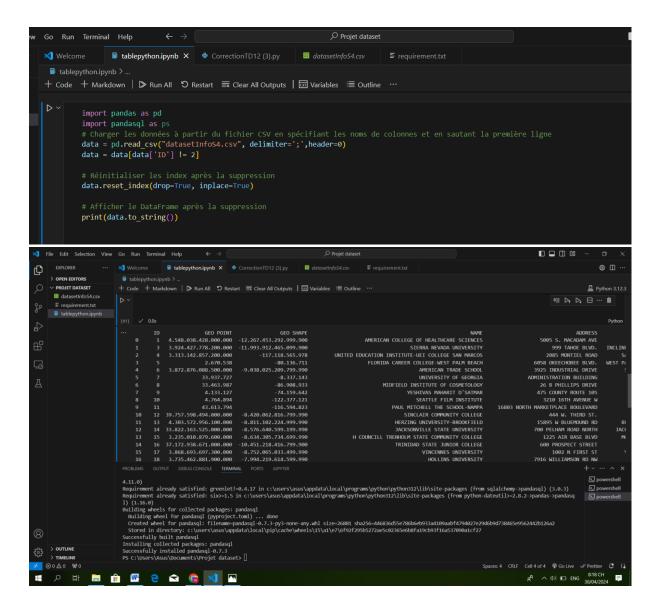
      print(data.to_string())
      ★ Projet dataset
```



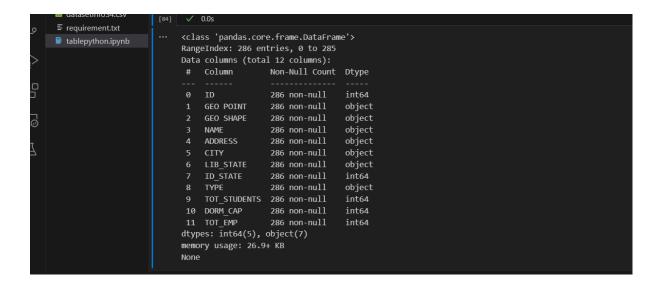
Deuxième méthode en utilisant mysql.connector :

```
from tabulate import tabulate
  connection=mysql.connector.connect(
          host='localhost',
          user='root',
database='us college'
  cursor= connection.cursor()
  #Exécution de la requête
query='SELECT * FROM `school`'
  cursor.execute(query)
columns = [col[0] for col in cursor.description]
  result=cursor.fetchall()
  print(tabulate([row for row in result], headers=columns))
  cursor.close()
  connection.close()
ID GEO POINT
                                        GEO SHAPE
                                                                                                                                                                   ADDRESS
                                                                                                                                                                   5005 S. MACADAM AVE
374 WHITMORE BUILDING 181 PRESIDENTS DRIVE
     42.388.647
                                        -72.529.312
                                                                             UNIVERSITY OF MASSACHUSETTS-AMHERST
     3.924.427.778.200.000
3.313.142.857.200.000
                                       -72.529.312 UNITERSTITY OF PRESSAURISETTS-APPERENT
-11.993.912.465.099.900 STERRA NEVADA UNIVERSITY
-117.118.565.978 UNITED EDUCATION INSTITUTE-UEI COLLEGE SAN MARCOS
-80.136.711 FLORIDA CAREER COLLEGE-MEST PALM BEACH
                                                                                                                                                                  999 TAHOE BLVD.
2085 MONTIEL ROAD
6058 OKEECHOBEE BLVD.
                                                                                                                                                                                                                                   INCLII
                                                                                                                                                                                                                                   SAN M
WEST I
     3.872.876.088.500.000
                                       -9.038.025.209.799.990 AMERICAN TRADE SCHOOL
                                                                                                                                                                   3925 INDUSTRIAL DRIVE
                                                                                                                                                                                                                                   SAINT
                                       -9.038.025.203...
-8.337.143
-86.908.933
-74.159.642
-422-377.121
     33.937.727
33.463.987
4.133.127
                                                                           UNIVERSITY OF GEORGIA
MIDFIELD INSTITUTE OF COSMETOLOGY
YESHIVAS MAHARIT D'SATMAR
                                                                                                                                                                  ADMINISTRATION BUILDING
26 B PHILLIPS DRIVE
475 COUNTY ROUTE 105
                                                                                                                                                                                                                                   ATHEN:
                                                                                                                                                                                                                                   MONROI
     4.764.894 -122.377.121
43.613.794 -116.594.823
39.757.598.494.000.000 -8.420.062.816.799.990
                                                                           SEATTLE FILM INSTITUTE
PAUL MITCHELL THE SCHOOL-NAMPA
SINCLAIR COMMUNITY COLLEGE
                                                                                                                                                                  3210 16TH AVENUE W
16803 NORTH MARKETPLACE BOULEVARD
                                                                                                                                                                   444 W. THIRD ST.
     4.303.572,956.100.000 -8.811.102.224.999,990
33.822.163.525.000.000 -8.576.640.599.199.990
3.235.010.879.600.000 -8.634.305.734.699.990
                                                                            HERZING UNIVERSITY-BROOKFIELD
JACKSONVILLE STATE UNIVERSITY
H COUNCILL TRENHOLM STATE COMMUNITY COLLEGE
                                                                                                                                                                   15895 W BLUEMOUND RD
                                                                                                                                                                                                                                   BROOK
                                                                                                                                                                  700 PELHAM ROAD NORTH
1225 AIR BASE BLVD
     37.172.938.671.000.000
                                        -10.451.218.416.799.900
-8.752.065.033.499.990
                                                                             TRINIDAD STATE JUNIOR COLLEGE
                                                                                                                                                                   600 PROSPECT STREET
1002 N FIRST ST
     3 868 693 697 300 000
                                                                            VINCENNES UNIVERSITY
```

2. Suppression d'un enregistrement à partir du programme Python : lci on supprime l'enregistrement d'identifiant ID = 2.



3. Contrôles de saisie pour garantir les contraintes de la base :



ETAPE 2: SQL

i.

1. Importation des données du dataset avec phpMyAdmin dans la base de données MySQL "projet2"

Table "state"

Structure:



Quelques enregistrements:

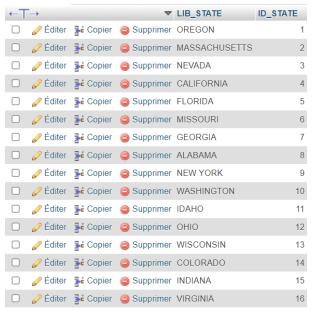
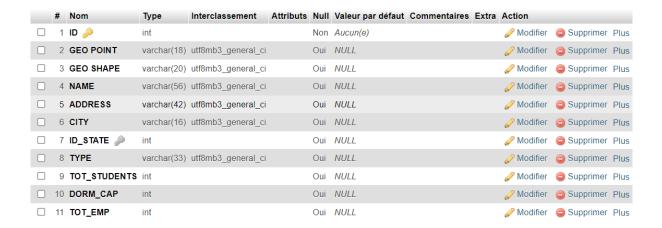


Table "school"

Structure:



Quelques enregistrements:

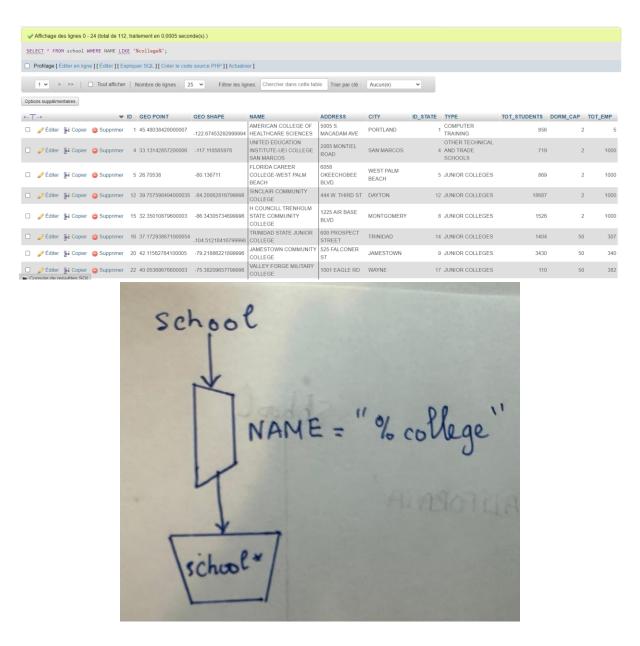
ID	GEO POINT	GEO SHAPE	NAME	ADDRESS	CITY	ID_STATE	TYPE	TOT_STUDENTS	DORM_CAP	TOT_EMP
1	45.48038428000007	-122.67453292999994	AMERICAN COLLEGE OF HEALTHCARE SCIENCES	5005 S. MACADAM AVE	PORTLAND	1	COMPUTER TRAINING	856	2	5
2	42.388647	-72.529312	UNIVERSITY OF MASSACHUSETTS- AMHERST	374 WHITMORE BUILDING 181 PRESIDENTS DRIVE	AMHERST	2	COLLEGES	6941	24701	31642
3	39.24427778200004	-119.93912465099999	SIERRA NEVADA UNIVERSITY	999 TAHOE BLVD.	INCLINE VILLAGE	3	COLLEGES	146	471	617
4	33.13142857200006	-117.118565978	UNITED EDUCATION INSTITUTE-UEI COLLEGE SAN MARCOS	2085 MONTIEL ROAD	SAN MARCOS	4	OTHER TECHNICAL AND TRADE SCHOOLS	719	2	1000
5	26.70538	-80.136711	FLORIDA CAREER COLLEGE-WEST PALM BEACH	6058 OKEECHOBEE BLVD.	WEST PALM BEACH	5	JUNIOR COLLEGES	869	2	1000
6	38.72876088500004	-90.38025209799997	AMERICAN TRADE SCHOOL	3925 INDUSTRIAL DRIVE	SAINT ANN	6	OTHER TECHNICAL AND TRADE SCHOOLS	128	2	1000
7	33.937727	-83.37143	UNIVERSITY OF GEORGIA	ADMINISTRATION BUILDING	ATHENS	7	COLLEGES	4196	34951	39147
8	33.463987	-86.908933	MIDFIELD INSTITUTE OF COSMETOLOGY	26 B PHILLIPS DRIVE	MIDFIELD	8	COSMETOLOGY AND BARBER SCHOOLS	17	2	1000

2. Introduction des requêtes SQL:

 3 requêtes SQL avec un "SELECT FROM WHERE" et des conditions de types différents

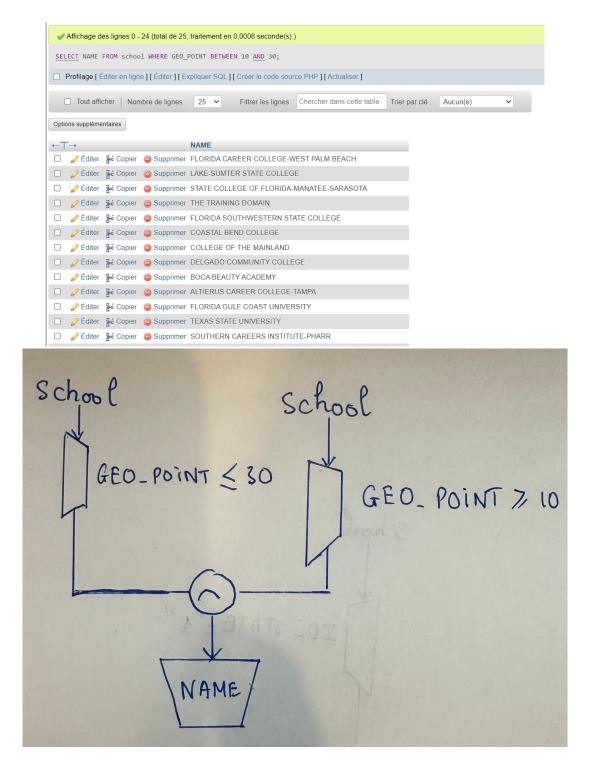
Condition de type "like" : SELECT * FROM school WHERE NAME LIKE '%college%';

Cette requête renvoie toutes les écoles dont le nom contient "college".

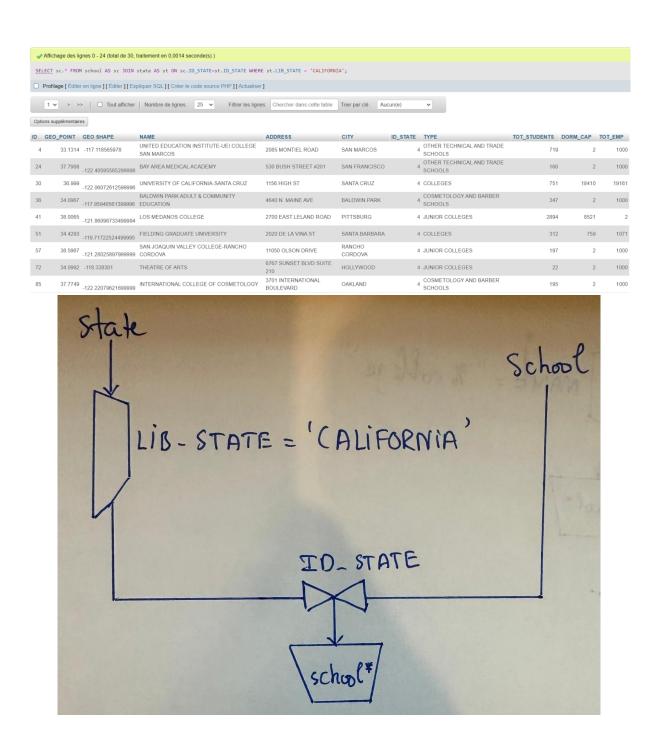


Condition de type "between" : SELECT NAME FROM school WHERE GEO_POINT BETWEEN 10 AND 30 ;

Cette requête renvoie le nom des écoles dont la coordonnée géographique est comprise dans la fourchette 10-30.



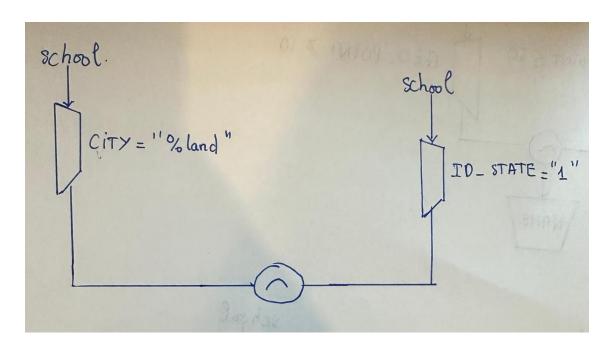
Condition avec une jointure : SELECT sc.* FROM school AS sc JOIN state AS st ON sc.ID_STATE = st.ID_STATE WHERE st.LIB_STATE = 'CALIFORNIA';



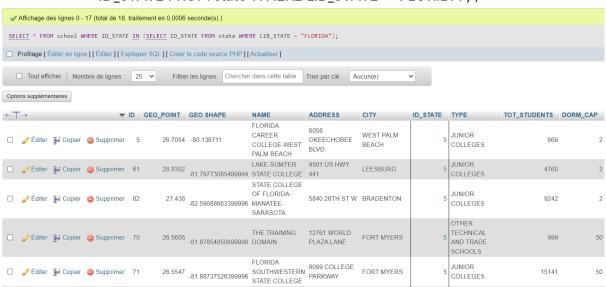
2) 2 requêtes SQL avec 2 "SELECT FROM WHERE" imbriqués utilisant des conditions de types différents

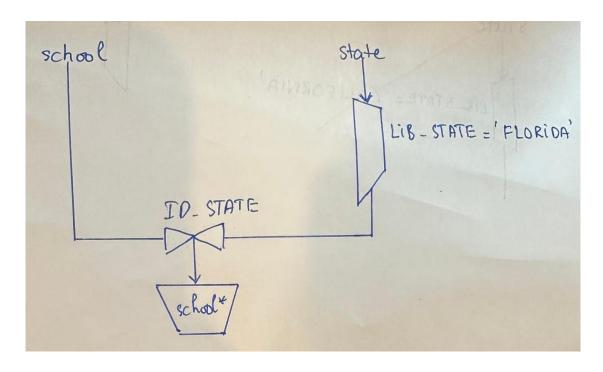
Conditions de type |N et "like": SELECT * FROM school WHERE ID_STATE = 1 AND CITY IN (SELECT CITY FROM school WHERE CITY LIKE "%land%");





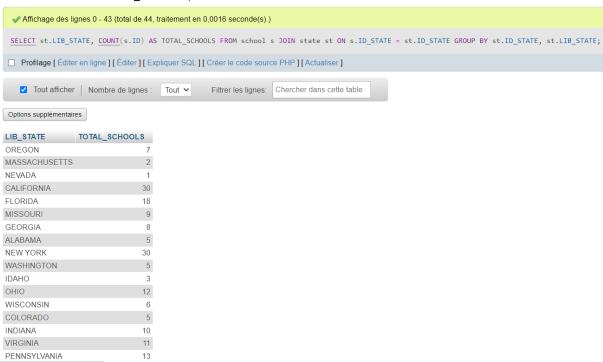
Condition de type |N : SELECT * FROM school WHERE ID_STATE IN (SELECT ID_STATE FROM state WHERE LIB_STATE = "FLORIDA") ;





3) Requête SQL avec un "GROUP BY":

SELECT st.LIB_STATE, COUNT(s.ID) AS TOTAL_SCHOOLS FROM school s JOIN state st ON s.ID_STATE = st.ID_STATE GROUP BY st.ID_STATE, st.LIB_STATE;



4) Requête SQL avec un "GROUP BY HAVING COUNT":

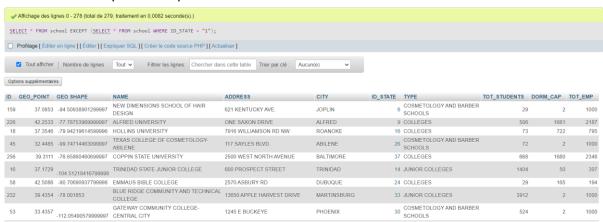
SELECT s.ID_STATE, ST.LIB_STATE, COUNT(s.ID) AS TOTAL_SCHOOLS FROM school s INNER JOIN state st ON s.ID_STATE = st.ID_STATE GROUP BY S.ID_STATE, ST.LIB_STATE HAVING COUNT(s.ID) > 10;

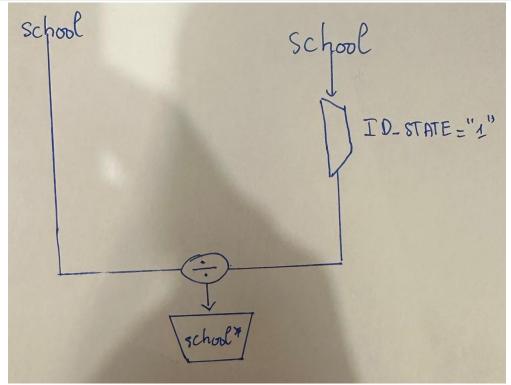


5) Requête réalisant une différence :

SELECT * FROM school EXCEPT (SELECT * FROM school WHERE ID_STATE = "1");

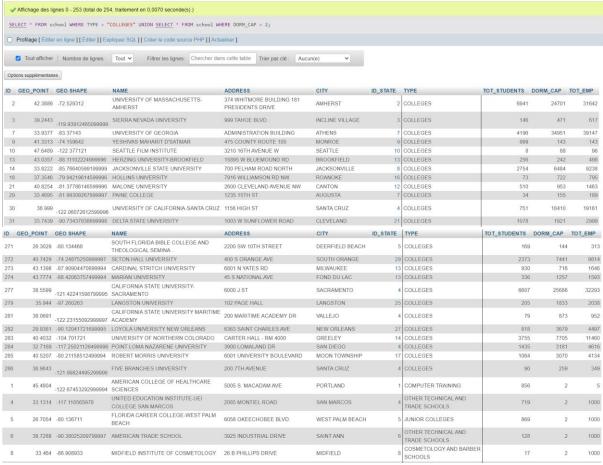
Cette requête renvoie toutes les écoles qui ne sont pas dans l'état d'identifiant 1 (OREGON).

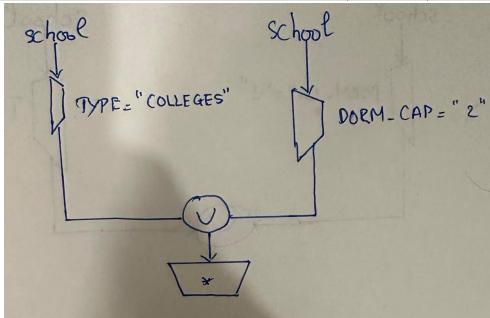




Requête réalisant une union :

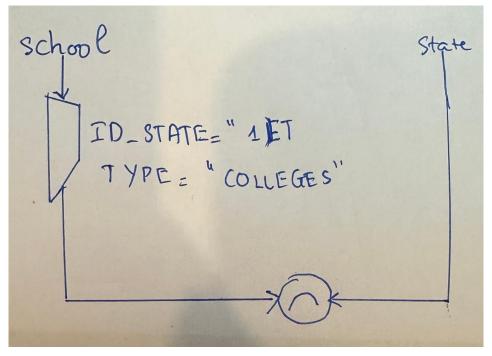
SELECT * FROM school WHERE TYPE = 'COLLEGES' UNION SELECT * FROM school WHERE DORM_CAP = 2;





Requête réalisant une intersection :

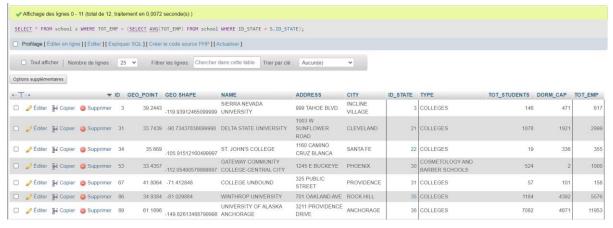
La requête suivante ne fonctionne pas car "INTERSECTION" n'est pas un opérateur standard en SQL : SELECT * FROM school WHERE ID_STATE = 1 INTERSECTION SELECT * FROM school WHERE TYPE = "COLLEGES";



Requête réalisant une division :

Cette requête renvoie les écoles qui ont un nombre total d'employés égal à la moyenne par état.

SELECT * FROM school s WHERE TOT_EMP = (SELECT AVG(TOT_EMP) FROM school WHERE ID_STATE = S.ID_STATE)



Requête utilisant l'opérateur "all":

Cette requête renvoie les écoles ayant un nombre total d'étudiants supérieur à tous les autres dans l'état d'identifiant 15 (INDIANA).

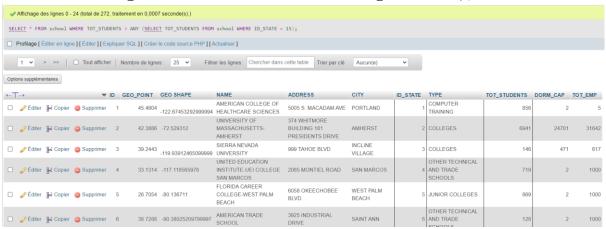
SELECT * FROM school WHERE TOT_STUDENTS > ALL (SELECT
TOT_STUDENTS FROM school WHERE ID_STATE = 15);



Requête utilisant l'opérateur "any":

Cette requête renvoie les écoles ayant un nombre total d'étudiants supérieur à au moins une autre école dans l'état d'identifiant 15 (INDIANA).

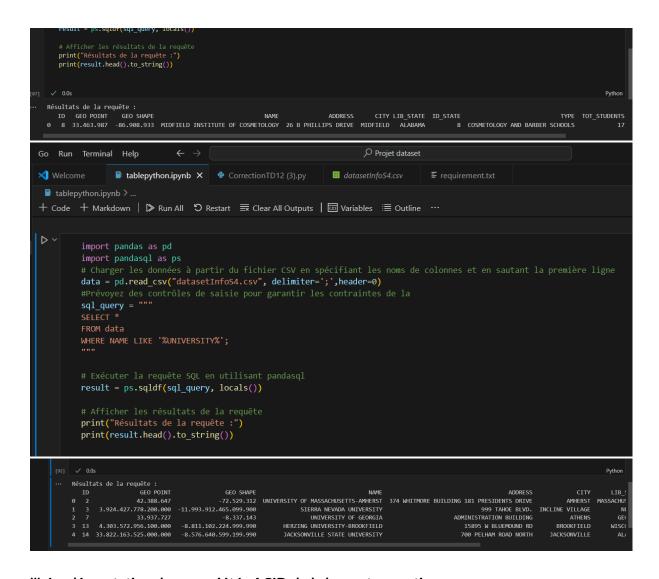
SELECT * FROM school WHERE TOT_STUDENTS > ANY (SELECT TOT_STUDENTS FROM school WHERE ID_STATE = 15);



ii. Introduction de requêtes SQL dans PYTHON:

1. Introduction dans le code Python de l'étape 1 d'une requête SQL du type "SELECT FROM WHERE"

```
import pandas as pd
import pandas as pandas as
```



- iii. Implémentation des propriétés ACID de la base : transaction
- 1. et 2. Implémentation dans le programme Python d'un commit et d'un roll back

```
ction View Go Run Terminal Help
                                                                                                   Projet dataset
              ⋈ Welcome
                                  ■ datasetInfoS4.csv
                                                                                                                     tablepython.ipynb > ...
              + Code + Markdown | ▶ Run All ち Restart ➡ Clear All Outputs | ➡ Variables ➡ Outline …
SET
oS4.csv
nt.txt
                         import pandas as pd
                         import pandasql as ps
                         import mysql.connector
                              connection = mysql.connector.connect(
                                   host='localhost',
                                   user='root',
                                   database='us_college'
                         except mysql.connector.Error as err:
                              print("Erreur de connexion à la base de données:", err)
                              exit()
                         with connection.cursor() as cursor:
                                   connection.start_transaction()
                                                                                                                                          × Welcome
                     ■ datasetInfoS4.csv = requirement.txt
      + Code + Markdown | ▶ Run All り Restart 🗮 Clear All Outputs | 🖾 Variables 🗏 Outline …
                     # Charger les données à partir du fichier CSV en spécifiant les noms de colonnes et en sautant la première ligne data = pd.read_csv("datasetInfoS4.csv", delimiter=';', header=0)
                     sql_query =
SELECT *
                     WHERE NAME LIKE '%UNIVERSITY%';
                     # Exécuter la requête SQL en utilisant pandasql
result = ps.sqldf(sql_query, locals())
                     # Afficher les résultats de la requête
print("Résultats de la requête :")
print(result.head().to_string())
                     connection.commit()
print("Transaction confirmée.")
```

```
# Exécuter la requête SQL en utilisant pandasql
result = ps.sqldf(sql_query, locals())

# Afficher les résultats de la requête
print("Résultats de la requête :")
print(result.head().to_string())

# Commit de la transaction
connection.commit()
print("Transaction confirmée.")

except mysql.connector.Error as err:
# Rollback en cas d'erreur
print("Erreur lors de l'exécution de la requête:", err)
print("Rollback de la transaction.")
connection.rollback()

# Fermeture automatique de la connexion à la fin du bloc with
```